


Base 04 — Bike Sales in Europe

Fonte, período e características gerais da série-alvo

Ficha da base

Fonte dos dados	Kaggle — <i>Bike Sales in Europe</i> (autor: sadiqshah): kaggle.com/datasets/sadiqshah/bike-sales-in-europe (arquivo Sales.csv)
Variável-alvo	Revenue — receita total das vendas (bicicletas, acessórios e vestuário), somada por mês. A base original é transacional: cada linha é uma venda, com quantidade, custo, preço, lucro e receita, em lojas de seis países.
Unidade	Unidade monetária da própria base (a moeda não é informada no Kaggle). Os modelos trabalham com a receita em milhões.
Frequência	Mensal (MS). Os dados originais são transacionais, sem frequência regular, e foram regularizados por soma mensal.
Período coberto	Base bruta: 01/01/2011 a 31/07/2016. Série mensal final: 01/2011 a 06/2016 (jul/2016 foi removido por estar incompleto).
Nº de observações	113.036 transações brutas (112.036 após remover 1.000 duplicatas exatas) e 66 meses na série final (60 observados e 6 imputados).
Horizonte de previsão definido	$h = 1$ mês à frente; a origem da previsão é o último dia do mês anterior.
Justificativa da escolha da base	Série de receita com sazonalidade moderada ($F_s = 0,33$) e várias dimensões (categoria, país, gênero, idade) que permitem construir variáveis externas. Isso permite comparar modelos com e sem exógenas. Em contrapartida, a série é curta (66 meses) e tem mudanças de nível, o que a torna um bom teste de robustez.

Gráfico da série-alvo



A série tem três regimes. De 2011 a meados de 2013 o nível é baixo e estável (cerca de 0,5 a 1,1 milhão por mês), com vendas só de Bikes. A partir de jul/2013, com a entrada de Accessories e Clothing, a receita salta para 1,2–3,0 milhões e os picos se repetem em dezembro. Em jan/2015 há uma queda abrupta para cerca de 0,65 milhão, nível semelhante ao do início da série, e uma nova subida a partir de jul/2015, chegando a 3,8 milhões em dez/2015 e a 3,6 milhões em jun/2016.

Os pontos em vermelho são os 6 meses imputados (jul–dez/2014). Eles não têm registros: jul/2014 só tem Accessories e Clothing, e de ago a dez/2014 não há nenhuma transação. A base também tem **anos espelhados**: 2012, 2015 e 2016 repetem 100% das combinações de 2011, 2013 e 2014. É um artefato de construção da base, e por isso não se usa lag de 24 meses. As mudanças de nível vêm do mix de produtos, não do calendário.

Variáveis externas

Dicionário de variáveis e disponibilidade real na data de previsão

Dicionário de variáveis

Variável	Descrição	Unidade	Fonte
mes_sin, mes_cos	Encoding cíclico do mês do calendário	—	Calendário
preco_medio	Média de Unit_Price nas transações do mês (indicador de mix, pois cada produto tem preço fixo)	moeda/unidade	Sales.csv (derivada)
custo_medio	Média de Unit_Cost nas transações do mês (também reflete o mix)	moeda/unidade	Sales.csv (derivada)
n_transacoes	Número de transações no mês	contagem	Sales.csv (derivada)
idade_media	Idade média dos clientes no mês	anos	Sales.csv (derivada)
pct_cat_*	Participação de Bikes, Accessories e Clothing na quantidade vendida	proporção	Sales.csv (derivada)
pct_pais_*	Participação de cada país (Australia, Canada, France, Germany, United Kingdom, United States) na quantidade vendida	proporção	Sales.csv (derivada)
pct_genero_*	Participação de cada gênero (F, M) dos clientes na quantidade vendida	proporção	Sales.csv (derivada)



A base não traz nenhuma variável de preço planejado com variação no tempo: os 130 produtos têm um único Unit_Price e um único Unit_Cost em todo o período. Uma previsão de preço ou promoção conhecida antecipadamente teria que vir de fonte externa.

Disponibilidade na data de origem da previsão

Variável	Disponível no futuro?	Tratamento adotado
mes_sin, mes_cos	conhecida antecipadamente	Usar o valor real do mês previsto (única variável contemporânea).
preco_medio, custo_medio, idade_media, n_transacoes	indisponível — vazamento	Defasadas em 1 mês (<code>_lag1</code>): só são conhecidas junto com o próprio alvo.
pct_cat_*, pct_pais_*, pct_genero_*	indisponível — vazamento	Defasadas em 1 mês (<code>_lag1</code>).
Order_Quantity, Cost, Profit do mesmo mês	indisponível — vazamento	Excluídas: não entram como preditoras, pois só são conhecidas junto com a receita.

Todas as variáveis realizadas entram com lag de 1 mês, então o valor do mês $t-1$ está disponível no fim desse mês, na origem da previsão do mês t ($h = 1$). A versão anterior do trabalho usava `preco_medio` e `custo_medio` do mesmo mês como se fossem preço planejado, o que era vazamento. Como cada produto tem preço fixo, a média mensal só varia pelo mix vendido, que é um resultado realizado. Nos meses inválidos (jul-dez/2014), as externas realizadas são preenchidas com o último valor válido (`ffill`), sem olhar para o futuro. Como `pct_genero_F = 1 - pct_genero_M`, só uma delas entra no pool do SARIMAX, para evitar colinearidade perfeita.

Gráficos das variáveis externas



O preço médio por transação cai de cerca de 2.000 para cerca de 300–400 quando Accessories e Clothing entram no mix (jul/2013 a dez/2014 e jul/2015 em diante). Isso mostra que a variável mede o mix, e não uma decisão de preço. A participação de Bikes cai de 100% para cerca de 2% nesses mesmos períodos, o que explica o espelhamento da base.

Limpeza e exploração

Qualidade dos dados antes da modelagem

Diagnóstico

Valores ausentes	Nenhum valor ausente nas colunas da base bruta. Na série mensal há 6 meses inválidos: jul/2014 (incompleto, só Accessories e Clothing, sem nenhuma Bike) e ago-dez/2014 (sem nenhum registro). Ainda há jul/2016, também incompleto e no fim da série. Os meses de jul-dez/2014 foram imputados com o valor do mesmo mês do ano anterior ($y[t-12]$), e jul/2016 foi removido.
Duplicidades	1.000 linhas duplicadas exatas, removidas antes da agregação (113.036 → 112.036 linhas).
Irregularidades temporais	Os dados são transacionais, sem frequência regular, e a série tem lacuna em ago-dez/2014. A série foi regularizada em calendário mensal completo (MS), por soma mensal, incluindo os meses sem registro. Isso mantém $m = 12$ representando 12 meses e evita que os lags cruzem o buraco. Além disso, os anos de 2012, 2015 e 2016 repetem 100% das combinações de 2011, 2013 e 2014 (anos espelhados).
Valores atípicos (outliers)	Por IQR no nível da transação, Revenue tem 14.765 atípicos (13,06%) e Order_Quantity tem 0. Na série mensal, nenhum mês é atípico por IQR. Os atípicos transacionais refletem a diferença de preço entre bicicletas e acessórios, e foram mantidos.

Decisões de limpeza e transformação


As duplicatas exatas foram removidas, pois não representam vendas distintas. Os atípicos de Revenue foram mantidos: são a diferença natural entre uma bicicleta e um acessório, e não erros de registro.

Jul/2014 e jul/2016 só têm Accessories e Clothing, sem nenhuma Bike (categoria presente em todos os demais meses). São meses incompletos, no último mês de cada bloco de extração, e não podem ser tratados como reais. Jul/2016 está no fim da série e foi removido, então o teste não o inclui. Os meses inválidos do meio (jul–dez/2014) foram tratados como ausentes e imputados por $y[t-12]$, usando só informação anterior à lacuna. Os meses imputados nunca são origem de validação ou de teste.

Como o preço e o custo de cada produto são fixos (0 de 130 produtos com mais de um preço ou custo), a média mensal desses campos é só um indicador de mix e entra defasada. Transformações foram tratadas como hiperparâmetros: o log no SARIMAX (a configuração escolhida o usa) e o Box-Cox no Holt-Winters (a configuração escolhida não o usa). O alvo é modelado em milhões, por estabilidade numérica, e as exógenas do SARIMAX são padronizadas (StandardScaler ajustado só no treino de cada origem). Pelo mesmo motivo de espelhamento, não se usa lag de 24 meses.

Decomposição STL

Tendência, sazonalidade e resíduo



A STL (robusta, $m = 12$) usa só o período anterior ao teste (treino + validação), para que a escolha de m não use informação do bloco de teste.

Tendência

O nível é estável em 2011–2012, sobe de forma acentuada em meados de 2013, quando entram Accessories e Clothing, e fica em patamar mais alto em 2014. A tendência cai na parte final por causa do retorno ao patamar baixo em jan/2015. A força de tendência alta reflete essas mudanças de nível mais do que um crescimento contínuo.

Sazonalidade

A sazonalidade é moderada, com picos recorrentes em dezembro. Parte do componente sazonal com $m = 6$ e $m = 12$ captura o salto de julho, que é uma mudança estrutural e não um padrão de calendário.

Essa é uma limitação a declarar. Para escolher o período sazonal foram testados $m = 3, 4, 6$ e 12 . Os dois maiores valores de F_s definiram os candidatos do SARIMAX e do Holt-Winters: $m \in \{6, 12\}$.

Resíduo

O resíduo é concentrado nos meses de quebra (jul/2013, jan/2015) e na lacuna imputada. Fora desses períodos fica próximo de zero. Ainda há estrutura remanescente, porque a STL não captura mudanças bruscas de nível.

Força da sazonalidade / tendência

Métrica	Valor	Interpretação
Força da tendência ($m = 12$)	0,509	Moderada a alta, puxada pelas mudanças de nível. Com $m = 3, 4$ e 6 chega a $0,78\text{--}0,81$.
Força da sazonalidade ($m = 12$)	0,330	Moderada. Para $m = 6$ é $0,395$ (a maior), para $m = 4$ é $0,040$ e para $m = 3$ é $0,000$.

Estacionariedade (treino + validação, $n = 42$): a série em nível é não estacionária (ADF $p = 1,000$ e KPSS $p = 0,021$). Com a diferença simples $\Delta 1$ fica estacionária (ADF $p < 0,001$ e KPSS $p = 0,100$). Com $\Delta 12$ isolada não (ADF $p = 0,968$), e com $\Delta 1\Delta 12$ (ADF $p = 0,019$ e KPSS $p = 0,100$) sim. O grid do SARIMAX testa d , $D \in \{0, 1\}$.

Feature engineering

Construção das features usadas nos modelos baseados em tabela

Features construídas

Tipo	Descrição	Usada em quais modelos
Lags da variável-alvo	lag_1, lag_2, lag_3, lag_6, lag_12 (5 features)	Random Forest, XGBoost. O SARIMAX não usa lags do alvo como exógenas, pois os termos AR/MA já os modelam.
Lags de variáveis externas	15 externas defasadas em 1 mês (_lag1): preco_medio, custo_medio, idade_media, n_transacoes, 3 de categoria (pct_cat_*), 6 de país (pct_pais_*) e 2 de gênero (pct_genero_*)	Random Forest e XGBoost (as 15). SARIMAX: combinações de 3 itens do pool (a escolhida usa idade_media_lag1, pct_cat_Accessories_lag1 e pct_pais_Germany_lag1).
Estatísticas de janela móvel	Média e desvio-padrão móveis de 3, 6 e 12 meses, calculados sobre y.shift(1) (6 features: roll_mean_* e roll_std_*)	Random Forest, XGBoost
Features de calendário	Mês do ano (via encoding cíclico). Não há dia da semana nem feriado, porque a série é mensal.	Random Forest, XGBoost. SARIMAX: apenas como item do pool (conjuntos calendario).
Encoding cíclico	mes_sin = $\sin(2\pi \cdot \text{mês}/12)$ e mes_cos = $\cos(2\pi \cdot \text{mês}/12)$ (2 features)	Random Forest, XGBoost, SARIMAX (conjuntos que incluem calendário)
Outras features criadas	Variável alvo transformada em log (somente SARIMAX). O modo do alvo das árvores (nivel ou diferenca) foi tratado como hiperparâmetro. Holt-Winters usa só o próprio alvo.	SARIMAX (log), Random Forest e XGBoost (modo)

No total, Random Forest e XGBoost usam **28 features**: 11 do alvo (5 lags + 6 de janela), 2 de calendário e 15 externas.

Tratamento de NA gerado pelos lags/janelas

Para as árvores, as primeiras linhas sem histórico suficiente (warm-up de 12 meses, por causa de `lag_12` e das janelas de 12 meses) não entram como linhas de treino: a primeira linha com todas as features é jan/2012. Para o SARIMAX só falta o `_lag1` da primeira linha, então ele é ajustado a partir de fev/2011. Todos os SARIMAX, com ou sem exógenas, partem desse mesmo ponto, para que as configurações sejam comparáveis.

As mesmas features (`FEATURE_COLS`) são usadas no Random Forest e no modelo de especialização (XGBoost). Todas as janelas usam `shift(1)`, e todas as externas realizadas entram defasadas em 1 mês, então nada do que entra na linha do mês t é desconhecido no fim de $t-1$.

Protocolo walk-forward

Como a validação fora da amostra foi montada para esta base

Janela inicial de treino	36 meses: 01/2011 a 12/2013. A janela é expansiva: na origem t o treino usa todos os meses anteriores a t .
Horizonte de previsão	$h = 1$ mês.
Passo de avanço	1 mês: depois de prever t , o mês entra no histórico e o modelo é reajustado.
Nº de origens de previsão (folds)	24: 12 de validação (escolha de hiperparâmetros) e 12 de teste (resultado final).
Datas de origem	Validação: 2014-01 a 2014-06 e 2015-01 a 2015-06. São os 12 últimos meses observados antes do teste; os meses imputados (jul-dez/2014) não servem de origem. Teste: 2015-07 a 2016-06.
Conjunto de teste final	Os últimos 12 meses da série, de 01/07/2015 a 01/06/2016. Os hiperparâmetros escolhidos na validação ficam fixos no teste, e nenhuma decisão usa esse bloco.

Os 4 modelos desta base (SARIMAX, Holt-Winters, Random Forest e XGBoost) usam exatamente as mesmas origens, o mesmo horizonte e o mesmo bloco de teste, e foram otimizados pelo mesmo critério (MAE walk-forward nas mesmas origens de validação). Como referência há também dois modelos sem parâmetros, avaliados nas mesmas origens: o ingênuo ($y[t-1]$, MAE na validação 375.259) e o ingênuo sazonal ($y[t-12]$, o mesmo mês do ano anterior, MAE na validação 1.635.225).

Modelos e hiperparâmetros

Espaço de busca, procedimento e configuração final

SARIMAX

Espaço de busca	Etapa 1 (triagem): $p, q \in \{0,1,2\}$, $d \in \{0,1\}$, $P, Q \in \{0,1\}$, $D \in \{0,1\}$, $m \in \{6, 12\}$, em nível e em log (576 ajustes, 3 sem convergência). Etapa 2a: as 2 melhores ordens por AIC de cada grupo (transformação, d, D, m), sem exógenas e com 3 conjuntos-base (128 configurações). Etapa 2b: as 5 melhores ordens $\times$ todas as 454 combinações de 3 exógenas do pool de 15 itens (2.270 configurações, 27.240 ajustes).
Critério	AIC/BIC apenas como triagem, dentro de cada grupo com a mesma diferenciação e transformação. A decisão final é o menor MAE walk-forward na validação, entre as configurações com exógenas.
Variáveis externas incluídas	idade_media_lag1, pct_cat_Accessories_lag1 e pct_pais_Germany_lag1 (padronizadas). pct_pais_Germany_lag1 aparece nas 20 melhores combinações.
Configuração final	SARIMAX(0,1,2)(1,1,0) ₆ , alvo em log (previsões revertidas com exp). MAE de validação = 175.159, contra 251.536 do mesmo modelo sem exógenas (referência SARIMA).

Holt-Winters (referência univariada)

Tendência	Multiplicativa, não amortecida
Sazonalidade	Multiplicativa
Período sazonal	12 meses
Parâmetros de suavização	α, β e γ estimados por máxima verossimilhança em cada origem do walk-forward (os valores não são fixados nem registrados no notebook). Grade completa de 50 configurações (tendência nenhuma/aditiva/multiplicativa, amortecida ou não, sazonalidade nenhuma/aditiva/multiplicativa, $m \in \{6, 12\}$, com e sem Box-Cox). 7 delas falharam e foram descartadas. MAE de validação = 246.085.

Random Forest

Espaço de busca	<code>n_estimators</code> ∈ {100, 200, 300, 500}; <code>max_depth</code> ∈ {None, 3, 5, 8}; <code>min_samples_split</code> ∈ {2, 4, 8}; <code>min_samples_leaf</code> ∈ {1, 2, 4}; <code>max_features</code> ∈ {sqrt, 0,5, 1,0}; modo do alvo ∈ {nível, diferença}.
Método de otimização	Busca aleatória (ParameterSampler, 20 sorteios × 2 modos = 40 configurações) com o mesmo walk-forward de validação (12 origens) dos outros modelos.
Configuração final	<code>n_estimators</code> = 300, <code>max_depth</code> = None, <code>min_samples_split</code> = 4, <code>min_samples_leaf</code> = 4, <code>max_features</code> = sqrt, modo = nível. MAE de validação = 286.150.

Modelo de especialização — XGBoost

Principais hiperparâmetros	<code>n_estimators</code> , <code>max_depth</code> , <code>learning_rate</code> , <code>subsample</code> , <code>colsample_bytree</code> , <code>min_child_weight</code> , <code>reg_alpha</code> , <code>reg_lambda</code> , além do modo do alvo (nível ou diferença).
Intervalos testados	<code>n_estimators</code> ∈ {100, 200, 400, 600}; <code>max_depth</code> ∈ {2, 3, 4, 6}; <code>learning_rate</code> ∈ {0,01, 0,03, 0,05, 0,1, 0,2}; <code>subsample</code> ∈ {0,6, 0,8, 1,0}; <code>colsample_bytree</code> ∈ {0,6, 0,8, 1,0}; <code>min_child_weight</code> ∈ {1, 3, 5}; <code>reg_alpha</code> ∈ {0, 0,1, 1}; <code>reg_lambda</code> ∈ {1, 5, 10}.
Método de busca	Busca aleatória (40 sorteios × 2 modos = 80 configurações), pelo MAE do mesmo walk-forward de validação.
Configuração final	<code>n_estimators</code> = 600, <code>max_depth</code> = 6, <code>learning_rate</code> = 0,1, <code>subsample</code> = 1,0, <code>colsample_bytree</code> = 0,6, <code>min_child_weight</code> = 3, <code>reg_alpha</code> = 0, <code>reg_lambda</code> = 1, modo = nível. MAE de validação = 269.004.

Resumo dos MAE de validação



Modelo	MAE na validação
SARIMAX	175.159
Holt-Winters	246.085
XGBoost	269.004
Random Forest	286.150
Ingênuo (referência, $y[t-1]$)	375.259
Ingênuo sazonal (referência, $y[t-12]$)	1.635.225

Na validação o SARIMAX foi o melhor, mas esse resultado não se repetiu no teste (ver resultados). Os hiperparâmetros foram escolhidos só por esse critério.

Resultados comparativos (MAE)

Erro fora da amostra do protocolo walk-forward, apenas para esta base

Modelo	MAE	× ingênuo	× ingênuo sazonal	Ranking
SARIMAX	568.564	1,22	0,43	3º
Holt-Winters	237.760	0,51	0,18	1º
Random Forest	609.078	1,31	0,46	4º
XGBoost (especialização)	564.866	1,21	0,42	2º
Ingênuo (referência, $y[t-1]$)	465.221	1,00	0,35	—
Ingênuo sazonal (referência, $y[t-12]$)	1.334.140	2,87	1,00	—



Em vitórias por origem de previsão (menor erro absoluto no mês, entre os 4 modelos), o Holt-Winters venceu 8 dos 12 meses do teste, o SARIMAX 2, o XGBoost 2 e o Random Forest 0. Tempo médio por

origem: Holt-Winters 0,09 s, SARIMAX 0,30 s, Random Forest 0,37 s e XGBoost 0,92 s (as duas referências ingênuas são instantâneas).


As duas referências. O ingênuo sazonal ($y[t-12]$) é o pior de todos (MAE 1.334.140, 2,9 vezes o ingênuo simples). Repetir o mesmo mês do ano anterior erra muito porque o nível da série muda com o mix de produtos, e não com o calendário: em jan–jun/2016 o mês de referência (jan–jun/2015) está no patamar baixo, enquanto o real fica entre 2,4 e 3,6 milhões, com erros de 1,8 a 2,8 milhões. Nas origens de jul–dez/2015 o mês de referência é um valor imputado (jul–dez/2014). Todos os quatro modelos ficam abaixo dele (razões de 0,18 a 0,46), mas só o Holt-Winters também ficou abaixo do ingênuo simples.

Por que o Holt-Winters venceu. Ele foi o único modelo que ficou abaixo da referência ingênuo (razão 0,51, contra 1,21 a 1,31 dos outros). A série é curta (66 meses), com sazonalidade moderada ($F_s = 0,33$) e mudanças de nível que vêm do mix de produtos, não de variáveis que os modelos consigam antecipar. O Holt-Winters multiplicativo, com sazonalidade de 12 meses e tendência multiplicativa, se reajusta a cada origem e acompanha o nível recente. Random Forest e XGBoost tiveram quase todos os resíduos positivos (100% e 92%), ou seja, subestimaram a receita no teste. Isso é coerente com o limite das árvores de não extrapolar além da faixa vista no treino, numa série com saltos de nível, mas essa explicação é uma hipótese consistente com os resíduos, e não foi testada à parte. O SARIMAX, que lidera na validação (175.159), piorou muito no teste (568.564). Os maiores erros do SARIMAX e do Holt-Winters estão em jul/2015, quando a série sobe de nível, e os do Random Forest e do XGBoost em dez/2015. As variáveis externas, aliás, não ajudaram o SARIMAX fora da amostra: seus coeficientes não são significativos (ver página 10), e escolher a melhor entre 2.270 configurações com só 12 pontos de validação favorece o sobreajuste à validação.


Análise dos resíduos

Erros fora da amostra, por modelo


Resíduos fora da amostra — SARIMAX (milhões)



Resíduos fora da amostra — Holt-Winters (milhões)




Resíduos fora da amostra — Random Forest (milhões)




2015-07 2015-09 2015-11 2016-01 2016-03 2016-05


Resíduos fora da amostra — XGBoost (milhões)




ACF dos resíduos — SARIMAX




ACF dos resíduos — Holt-Winters



ACF dos resíduos — Random Forest






Modelo	Estatística Ljung-Box	p-valor	Interpretação
SARIMAX	lag 3: 4,68 lag 6: 9,26	lag 3: 0,197 lag 6: 0,159	Sem indício de autocorrelação. Viés médio +43.297 (50% dos resíduos positivos) e desvio-padrão de 748.239, o maior dos quatro.
Holt-Winters	lag 3: 0,76 lag 6: 5,60	lag 3: 0,858 lag 6: 0,469	Sem indício de autocorrelação. Viés médio +193.462 (58% positivos) e desvio-padrão de 407.833.
Random Forest	lag 3: 5,24 lag 6: 12,64	lag 3: 0,155 lag 6: 0,049	Há indício de autocorrelação ($p < 0,05$ no lag 6). Viés médio +609.078 (100% positivos) e desvio-padrão de 362.356.
XGBoost	lag 3: 3,70 lag 6: 8,17	lag 3: 0,295 lag 6: 0,226	Sem indício de autocorrelação. Viés médio +547.124 (92% positivos) e desvio-padrão de 538.038.

Viés. Resíduo = real – previsto, então viés positivo é subestimação. Random Forest e XGBoost subestimam sistematicamente (viés médio de 609 mil e 547 mil, com 100% e 92% de resíduos positivos). O Holt-Winters tem viés pequeno e é puxado por dois meses (jul/2015 e jan/2016). O SARIMAX tem viés próximo de zero, mas erros grandes de sinais alternados (jul/2015 e jan/2016 positivos, fev e mar/2016 negativos), por isso o maior desvio-padrão.


Padrões remanescentes e autocorrelação. Em SARIMAX, Holt-Winters e XGBoost o Ljung-Box (lags 3 e 6) não rejeita ausência de autocorrelação. No Random Forest o lag 6 rejeita ($p = 0,049$), e seus resíduos são sempre positivos, com o pico em dez/2015 (cerca de 1,5 milhão). Com apenas 12 pontos por modelo o teste tem baixo poder: p-valor alto indica ausência de evidência, não prova de independência.

Diagnóstico dentro da amostra do SARIMAX final (ajustado em treino + validação): Ljung-Box com $p = 0,998$ (lag 6) e $p = 0,988$ (lag 12), sem autocorrelação residual nos dados de ajuste. O bom ajuste dentro da amostra contrasta com o erro fora dela, o que reforça o sobreajuste à validação.



Importância das features

Random Forest e modelo de especialização (SARIMAX via coeficientes)



As barras laranja são externas defasadas, as roxas são lags e janelas do alvo e as cinza são calendário. A permutação é avaliada no bloco de teste, no mesmo espaço do alvo do modelo.

SARIMAX — coeficientes das variáveis externas

Variável	Coeficiente	Sinal	Significância
idade_media_lag1	0,0071 (EP 0,0744)	positivo	p = 0,924 — não significativo
pct_cat_Accessories_lag1	0,2627 (EP 0,2802)	positivo	p = 0,349 — não significativo
pct_pais_Germany_lag1	0,0890 (EP 0,0916)	positivo	p = 0,332 — não significativo

Exógenas padronizadas e alvo em log(milhões): o coeficiente é o efeito de +1 desvio-padrão da exógena sobre o log da receita. Na parte ARIMA, só o termo AR sazonal ($ar.S.L6 = -0,576$; $p < 0,001$) é significativo. $ma.L1$ ($-0,452$; $p = 0,295$) e $ma.L2$ ($0,211$; $p = 0,411$) não são.

Random Forest e XGBoost. Na importância nativa do Random Forest, `lag_1` lidera, seguido de `preco_medio_lag1`, `pct_cat_Bikes_lag1` e `custo_medio_lag1`. No XGBoost (gain), `preco_medio_lag1` (cerca de 0,37), `n_transacoes_lag1` (cerca de 0,25) e `lag_1` (cerca de 0,16) concentram a maior parte. As externas defasadas somam **69,9%** da importância nativa do Random Forest e **74,4%** do gain do XGBoost. Na permutação, o ranking muda: no Random Forest lideram `lag_6`, `custo_medio_lag1` e `pct_cat_Accessories_lag1`, e no XGBoost `pct_pais_Australia_lag1` lidera com folga, seguida de `lag_1`, `mes_sin` e `lag_12`. A permutação não confirma a importância nativa, que favorece variáveis contínuas com muitos valores distintos (como preço médio e custo médio). Os aumentos de MAE por permutação são pequenos frente ao MAE do modelo (da ordem de milhares contra centenas de milhares), ou seja, nenhuma feature isolada explica o desempenho.

Papel das externas e disponibilidade. As externas têm papel relevante nas árvores, mas não melhoram o resultado final (esses modelos ficaram atrás do Holt-Winters, que não usa nenhuma). No SARIMAX, nenhuma externa é significativa. Todas as externas usadas estão defasadas em 1 mês e portanto são conhecidas na origem da previsão; o calendário é conhecido antecipadamente.

Conclusão desta base

O melhor modelo na base *Bike Sales in Europe* foi o **Holt-Winters** (MAE 237.760, 0,51 × o modelo ingênuo, 8 vitórias em 12 origens), seguido por XGBoost (564.866), SARIMAX (568.564) e Random Forest (609.078). Foi o único modelo que superou a referência ingênua (465.221); todos superaram a ingênua sazonal (1.334.140), que erra por não acompanhar as mudanças de nível. O modelo univariado venceu os que usam variáveis externas, porque a série é curta (66 meses) e o desempenho depende sobretudo de acompanhar as mudanças de nível e a sazonalidade moderada ($F_s = 0,33$), e não de variáveis explicativas.

Limitações específicas desta base. (i) Série curta, com 6 dos 66 meses imputados. (ii) Mudanças estruturais de nível (jul/2013, jan/2015, jul/2015) causadas pela entrada e saída de categorias no mix, e não por padrão de calendário. (iii) Anos espelhados (2012, 2015 e 2016 repetem 2011, 2013 e 2014), o que impede o uso de lag de 24 meses. (iv) Teste de apenas 12 pontos, logo o Ljung-Box tem baixo poder e a comparação entre modelos é sensível a poucos meses (jul/2015 e dez/2015). (v) Random Forest e XGBoost subestimam sistematicamente a receita no teste, o que é coerente com a dificuldade das árvores em extrapolar níveis. (vi) O SARIMAX vencedor na validação (175.159) piorou no teste (568.564), e suas exógenas não são significativas, indicando sobreajuste à validação (2.270 configurações para 12 origens). (vii) O resíduo do Random Forest mostra indício de autocorrelação (lag 6, $p = 0,049$).

Decisões metodológicas que precisaram de ajuste. Jul/2016 removido (mês incompleto) e jul/2014 tratado como ausente; meses sem registro (ago–dez/2014) imputados com $y[t-12]$, sem uso de dados do teste; todas as variáveis realizadas defasadas em 1 mês para evitar vazamento (inclusive `preco_medio` e `custo_medio`, que refletem só o mix); `pct_genero_F` descartada do pool por colinearidade com `pct_genero_M`; m escolhido pela força da sazonalidade ($m \in \{6, 12\}$); busca do SARIMAX em duas etapas (AIC/BIC como triagem e MAE walk-forward como decisão); e os quatro modelos otimizados pelo mesmo walk-forward nas mesmas origens de validação.