

Microsoft Stock — preço de abertura

Fonte, período e características gerais da série-alvo

Ficha da base

Fonte dos dados	Microsoft Stock Time Series Analysis — Kaggle
Variável-alvo	Open — preço de abertura da ação da Microsoft no pregão
Unidade	Dólares americanos (USD)
Frequência	Diária em dias de negociação (pregões)
Período coberto	01/04/2015 a 31/03/2021
Nº de observações	1.511 observações
Horizonte de previsão definido	h = 1 pregão à frente
Justificativa da escolha da base	Série relevante, longa e com mudanças de tendência e volatilidade suficientes para comparar modelos estatísticos e de aprendizado de máquina.

Gráfico da série-alvo



A abertura apresenta tendência predominante de alta, saindo da faixa de US\$ 40 em 2015 e superando US\$ 230 em 2021. Há correções e mudanças de volatilidade, com queda acentuada no início de 2020 e rápida recuperação posterior. Não se observa um ciclo semanal forte.

Variáveis externas

Dicionário de variáveis e disponibilidade real na data de previsão

Dicionário de variáveis



Variável	Descrição	Unidade	Fonte
Close	Fechamento da ação da Microsoft	USD	Base Microsoft Stock
Volume	Quantidade de ações negociadas	Ações	Base Microsoft Stock

Disponibilidade na data de origem da previsão

Variável	Disponível no futuro?	Tratamento adotado
Dia da semana e mês	conhecida antecipadamente	Usar encoding cíclico de seno e cosseno
Close e Volume	indisponível — vazamento	Usar apenas o valor do pregão anterior (lag 1)

Para prever a abertura no pregão t , fechamento e volume entram com defasagem de um pregão. As médias e os desvios móveis também terminam em $t-1$. Essa regra impede que informações ainda desconhecidas na origem da previsão sejam usadas no modelo.

Gráficos das variáveis externas



Limpeza e exploração

Qualidade dos dados antes da modelagem

Diagnóstico


Valores ausentes	A base final possui 0 valores ausentes nas colunas utilizadas.
Duplicidades	0 datas duplicadas após ordenação e deduplicação por data.
Irregularidades temporais	Os intervalos correspondem a fins de semana e feriados da bolsa. A unidade temporal foi mantida como pregão; não foram criados dias civis artificiais.
Valores atípicos (outliers)	O volume de 09/12/2019 aparece como 101.612 na fonte e foi corrigido para 16.687.400 somente na cópia de trabalho. Choques reais de preço e volatilidade foram preservados.

Decisões de limpeza e transformação

O arquivo original não foi alterado. As datas foram convertidas, a base foi ordenada e deduplicada, e o erro conhecido de volume foi corrigido apenas em memória. O volume recebeu transformação $\log_{1p}$ antes da defasagem. Não houve interpolação nem winsorização dos preços, pois movimentos extremos podem representar eventos reais do mercado.

Decomposição STL

Tendência, sazonalidade e resíduo



Tendência

A tendência estimada passa de aproximadamente US\$ 40,64 para US\$ 234,28. O movimento predominante é de alta, interrompido por correções — especialmente no início de 2020 — e seguido por recuperação.

Sazonalidade

Foi testado o período operacional de cinco pregões. A amplitude é pequena e instável; a força calculada é 0,000, portanto não há sazonalidade semanal relevante.

Resíduo

O resíduo concentra choques de mercado e períodos de maior volatilidade. Os picos ao redor de 2020 indicam movimentos que tendência e sazonalidade não explicam.

Força da sazonalidade / tendência

Métrica	Valor	Interpretação
Força da tendência	0,998	Tendência muito forte
Força da sazonalidade	0,000	Ciclo semanal sem força relevante

Feature engineering

Construção das features usadas nos modelos baseados em tabela

Features construídas

Tipo	Descrição	Usada em quais modelos
Lags da variável-alvo	Open em 1, 2, 3, 5 e 10 pregões	Random Forest e XGBoost
Lags de variáveis externas	Close e log do Volume em $t-1$	Random Forest, XGBoost e SARIMAX
Estatísticas de janela móvel	Média e desvio-padrão da abertura em janelas de 5 e 21 pregões, encerradas em $t-1$	Random Forest e XGBoost
Features de calendário	Dia da semana e mês	Random Forest e XGBoost
Encoding cíclico	Seno e cosseno do dia da semana e do mês	Random Forest e XGBoost
Transformação adicional	Logaritmo do volume antes da defasagem	Random Forest, XGBoost e SARIMAX

Tratamento de NA gerado pelos lags/janelas

As primeiras 21 linhas foram descartadas como período de aquecimento da maior janela móvel. Restaram 1.490 observações completas para modelagem, sem imputar valores gerados artificialmente.

Random Forest e XGBoost receberam exatamente as mesmas 15 features. Essa igualdade mantém a comparação justa entre o modelo de referência baseado em árvores e o modelo de especialização.

Protocolo walk-forward

Como a validação fora da amostra foi montada para esta base

Janela inicial de treino	1.118 observações, de 01/05/2015 a 08/10/2019
Horizonte de previsão	h = 1 pregão
Passo de avanço	1 pregão por iteração, com janela expansiva
Nº de origens de previsão (folds)	372 origens fora da amostra
Datas de origem	Todos os pregões consecutivos do teste, de 09/10/2019 a 31/03/2021
Conjunto de teste final	25% finais da base preparada: 372 observações

Confirmado: SARIMAX, Holt-Winters, Random Forest e XGBoost usam as mesmas 372 datas, o mesmo horizonte de um pregão e os valores reais entram no histórico somente após cada previsão.

Modelos e hiperparâmetros

Espaço de busca, procedimento e configuração final

SARIMAX

Espaço de busca	(1,1,0), (0,1,1) e (1,1,1); parte sazonal (0,0,0,5) ou (1,0,0,5)
Critério	Menor AIC no treino; BIC registrado como diagnóstico
Variáveis externas incluídas	Close e log do Volume em t-1, padronizados apenas com o treino
Configuração final	SARIMAX(1,1,1)×(1,0,0) ₅ ; AIC 2.467,12 e BIC 2.497,20

Holt-Winters (referência univariada)

Tendência	Aditiva e amortecida
Sazonalidade	Nenhuma na configuração vencedora
Período sazonal	5 pregões foi avaliado na alternativa sazonal; não se aplica ao modelo final
Parâmetros de suavização	Estimados internamente por máxima verossimilhança em cada ajuste

Random Forest

Espaço de busca	n_estimators: 100/200; max_depth: 3/6; min_samples_split: 2/5; min_samples_leaf: 1/5; max_features: sqrt
Método de otimização	Busca em grade, TimeSeriesSplit com 4 divisões e menor MAE
Configuração final	n_estimators=200, max_depth=6, min_samples_split=2, min_samples_leaf=1, max_features=sqrt


Modelo de especialização — XGBoost

Principais hiperparâmetros	n_estimators, max_depth, learning_rate, subsample e colsample_bytree
Intervalos testados	Árvores: 100/200; profundidade: 3/5; taxa: 0,03/0,10; amostragem de linhas e colunas: 0,8
Método de busca	Busca em grade, TimeSeriesSplit com 4 divisões e menor MAE
Configuração final	n_estimators=100, max_depth=3, learning_rate=0,10, subsample=0,8, colsample_bytree=0,8

Resultados comparativos (MAE)

Erro fora da amostra do protocolo walk-forward, apenas para esta base


Modelo	MAE	Ranking
SARIMAX	1,643 USD	1º
XGBoost	2,583 USD	2º
Holt-Winters	2,782 USD	3º
Random Forest	3,392 USD	4º



Com as exógenas corretas, o SARIMAX obteve o menor MAE, 1,643 USD. O XGBoost ficou em segundo lugar, com 2,583 USD. A vantagem do SARIMAX indica que a relação entre a abertura e o fechamento do pregão anterior é bem representada por sua estrutura dinâmica; o XGBoost continua competitivo ao combinar médias e lags recentes da abertura.

Análise dos resíduos

Erros fora da amostra, por modelo




Modelo	Estatística Ljung-Box	p-valor	Interpretação
SARIMAX	47,661	0,000474	Autocorrelação residual
Holt-Winters	23,309	0,2739	Sem evidência de autocorrelação a 5%
Random Forest	217,360	$4,01 \times 10^{-35}$	Autocorrelação residual
XGBoost	53,295	0,0000735	Autocorrelação residual

O SARIMAX apresenta leve superestimação média de 0,178 USD (resíduo médio $-0,178$). Os demais subestimam em média: 0,295 no Holt-Winters, 1,288 no Random Forest e 0,778 no XGBoost. Apenas o Holt-Winters não apresenta evidência de autocorrelação residual a 5%; SARIMAX, Random Forest e XGBoost ainda deixam estrutura temporal nos erros.

Importância das features

Random Forest, XGBoost e coeficientes do SARIMAX



SARIMAX — coeficientes das variáveis externas

Variável	Coeficiente	Sinal	Significância
Fechamento em t-1 (padronizado)	28,599	Positivo	Significativo (p < 0,001)
Log do volume em t-1 (padronizado)	0,047	Positivo	Significativo (p = 0,029)

No XGBoost, as três maiores importâncias são a média móvel de 21 pregões (41,2%), o fechamento em t-1 (23,4%) e a abertura em t-3 (22,0%). O log do volume tem importância nativa muito pequena no XGBoost, mas coeficiente significativo no SARIMAX. As exógenas entram apenas em t-1 para evitar vazamento; importância e significância não implicam causalidade.

Conclusão desta base

O SARIMAX foi o melhor modelo desta base, com MAE de 1,643 USD. O XGBoost, modelo de especialização do grupo, ficou em segundo lugar com 2,583 USD. O resultado reforça a relevância do fechamento do pregão anterior para prever a abertura seguinte. A sazonalidade semanal é desprezível, e o Holt-Winters vencedor não utilizou componente sazonal. As principais limitações são mudanças de regime, horizonte de apenas um pregão e autocorrelação residual em três modelos, inclusive SARIMAX e XGBoost. Recomenda-se reestimar os modelos periodicamente e monitorar MAE, viés e Ljung-Box.

Responsabilidade: Gabriel Bento realizou a análise da base Microsoft e a especialização em XGBoost. A comparação consolidada entre as cinco bases permanece no relatório coletivo do grupo. O notebook `main.ipynb` e os arquivos da pasta `resultados` preservam os dados, configurações, previsões, métricas, resíduos, importâncias e coeficientes utilizados neste relatório.