

# Nasdaq - Microsoft Stock

## Resumo executivo

---

Este recorte do trabalho analisa o preço de abertura ( **Open** ) da Microsoft e compara quatro modelos para prever o próximo pregão. O protocolo usa validação walk-forward, MAE e as mesmas datas de teste em todos os modelos. O SARIMAX obteve o menor MAE (2.647 USD). O XGBoost ficou em 3º lugar, com MAE de 2.934 USD.

- **Target:** preço de abertura ( **Open** ) do próximo pregão, em dólares.
- **Horizonte:** um pregão à frente.
- **Período:** 01/04/2015 a 31/03/2021.
- **Frequência:** pregões da bolsa, com sazonalidade operacional de cinco pregões.
- **Variáveis externas:** fechamento do NASDAQ Composite e do VIX, sempre defasados.
- **Modelos:** SARIMAX, Holt-Winters, Random Forest e XGBoost.
- **Métrica principal:** MAE fora da amostra.

## Responsabilidade

---

**Gabriel Bento** é responsável pela análise desta base e pela especialização em XGBoost. A comparação consolidada entre as cinco bases pertence ao relatório coletivo do grupo.

## Fonte da base

---

Os dados da Microsoft foram obtidos em [Microsoft Stock Time Series Analysis, no Kaggle](#). NASDAQ Composite e VIX foram incorporados como variáveis externas de mercado.

# Leitura, documentação e qualidade dos dados

A série-alvo representa o preço de abertura diário da ação da Microsoft em dólares. A auditoria verifica cobertura temporal, duplicidades, ausências e o registro incorreto de volume em 09/12/2019. O valor original é preservado no arquivo-fonte e corrigido somente na cópia de trabalho.

|   | Date       | Open  | High  | Low   | Close | Volume   | NASDAQ_Close | VIX_Close |
|---|------------|-------|-------|-------|-------|----------|--------------|-----------|
| 0 | 2015-04-01 | 40.60 | 40.76 | 40.31 | 40.72 | 36865322 | 4880.229980  | 15.11     |
| 1 | 2015-04-02 | 40.66 | 40.74 | 40.12 | 40.29 | 37487476 | 4886.939941  | 14.67     |
| 2 | 2015-04-06 | 40.34 | 41.78 | 40.18 | 41.55 | 39223692 | 4917.319824  | 14.74     |
| 3 | 2015-04-07 | 41.61 | 41.91 | 41.31 | 41.53 | 28809375 | 4910.229980  | 14.78     |
| 4 | 2015-04-08 | 41.48 | 41.69 | 41.04 | 41.42 | 24753438 | 4950.819824  | 13.98     |


|   | Verificação                               | Resultado  |
|---|-------------------------------------------|------------|
| 0 | Observações                               | 1511       |
| 1 | Data inicial                              | 2015-04-01 |
| 2 | Data final                                | 2021-03-31 |
| 3 | Datas duplicadas                          | 0          |
| 4 | Ausências externas antes do preenchimento | 0          |
| 5 | Valores ausentes finais                   | 0          |
| 6 | Volume original em 09/12/2019             | 101612     |
| 7 | Volume corrigido                          | 16687400   |

|   | Variável     | Significado                              | Unidade | Uso na previsão                 |
|---|--------------|------------------------------------------|---------|---------------------------------|
| 0 | Open         | Preço de abertura da MSFT                | USD     | Alvo no pregão t                |
| 1 | Close        | Preço de fechamento da MSFT              | USD     | Usado com defasagem de 1 pregão |
| 2 | Volume       | Quantidade negociada da MSFT             | Ações   | Usado com defasagem e log       |
| 3 | NASDAQ_Close | Fechamento do NASDAQ Composite           | Pontos  | Variável externa defasada       |
| 4 | VIX_Close    | Fechamento do índice de volatilidade VIX | Pontos  | Variável externa defasada       |

A junção final não contém ausências nem datas duplicadas. As diferenças entre datas consecutivas correspondem a fins de semana e feriados; a unidade temporal usada na modelagem é o pregão, não o dia civil.


## Disponibilidade temporal e prevenção de vazamento

Para prever a abertura no pregão  $t$ , o notebook usa somente informações conhecidas até  $t-1$ . NASDAQ, VIX, fechamento e volume entram defasados. As médias e os desvios móveis também são calculados a partir da abertura anterior. Assim, valores observados no próprio dia previsto não entram nas features.



## Decomposição STL e características temporais

O período sazonal é definido como cinco pregões, correspondente a uma semana operacional típica. A decomposição separa tendência, sazonalidade e resíduo, e a força sazonal é calculada pelo método apresentado em aula.



A tendência passa de aproximadamente **US\$ 40.64\*\* para \*\*US\$ 234.28**, indicando trajetória predominante de **alta** no período. A força sazonal semanal é **0.000**, portanto o ciclo de cinco pregões é fraco. O componente residual concentra choques de mercado e movimentos não explicados pela tendência.

# Feature Engineering

Foram criados lags da abertura, estatísticas móveis, variáveis de mercado defasadas e calendário com encoding cíclico. As primeiras 21 observações ficam incompletas por causa da maior janela móvel e são removidas antes da divisão temporal. Random Forest e XGBoost usam exatamente o mesmo conjunto de features.

Linhas disponíveis para modelagem: 1490  
Linhas iniciais removidas por lags e janelas: 21

|    | Feature              |
|----|----------------------|
| 0  | Open_lag_1           |
| 1  | Open_lag_2           |
| 2  | Open_lag_3           |
| 3  | Open_lag_5           |
| 4  | Open_lag_10          |
| 5  | Open_media_5         |
| 6  | Open_desvio_5        |
| 7  | Open_media_21        |
| 8  | Open_desvio_21       |
| 9  | Close_lag_1          |
| 10 | Log_Volume_lag_1     |
| 11 | NASDAQ_Close_lag_1   |
| 12 | NASDAQ_Retorno_lag_1 |
| 13 | VIX_Close_lag_1      |
| 14 | Dia_semana_sen       |
| 15 | Dia_semana_cos       |
| 16 | Mes_sen              |
| 17 | Mes_cos              |

[illegible]

## Separação temporal e protocolo walk-forward

---

Os 25% finais formam o teste e nunca participam da otimização. Dentro do treinamento, a busca usa `TimeSeriesSplit`, mantendo a ordem temporal. No teste final, cada modelo prevê um pregão, recebe a observação real e avança para a próxima origem de previsão. Os hiperparâmetros permanecem fixos.

Treino: 1118 observações

Teste: 372 observações

Período de teste: 2019-10-09 a 2021-03-31

## Otimização de Random Forest e XGBoost

A busca em grade usa quatro divisões temporais e MAE. Para Random Forest são testados número de árvores, profundidade, `min_samples_split`, `min_samples_leaf` e quantidade de features. Para XGBoost são testados número e profundidade das árvores, taxa de aprendizado, subamostragem de linhas e de colunas.

|   | Modelo        | MAE_CV   | Melhores parâmetros                                            |
|---|---------------|----------|----------------------------------------------------------------|
| 0 | Random Forest | 9.781062 | <code>{'max_depth': 6, 'max_features': 'sqrt', 'min_...</code> |
| 1 | XGBoost       | 9.600985 | <code>{'colsample_bytree': 0.8, 'learning_rate': 0.0...</code> |

Configuração escolhida para Random Forest: `{'max_depth': 6, 'max_features': 'sqrt', 'min_samples_leaf': 1, 'min_samples_split': 5, 'n_estimators': 100}`. Configuração escolhida para XGBoost: `{'colsample_bytree': 0.8, 'learning_rate': 0.03, 'max_depth': 3, 'n_estimators': 200, 'subsample': 0.8}`. A seleção foi feita somente com o conjunto de treinamento.

## Otimização de SARIMAX e Holt-Winters

O SARIMAX compara ordens não sazonais e sazonais com período cinco, escolhendo o menor AIC e registrando o BIC. As variáveis externas são padronizadas com parâmetros aprendidos apenas no treino. O Holt-Winters compara ausência ou presença de tendência, sazonalidade aditiva e tendência amortecida; os coeficientes de suavização são estimados internamente no treino.

|   | order     | seasonal_order | AIC         | BIC         |
|---|-----------|----------------|-------------|-------------|
| 0 | (1, 1, 1) | (1, 0, 0, 5)   | 3247.512025 | 3287.616151 |
| 1 | (1, 1, 0) | (1, 0, 0, 5)   | 3248.917522 | 3284.008632 |
| 2 | (1, 1, 1) | (0, 0, 0, 5)   | 3255.545546 | 3290.661814 |
| 3 | (1, 1, 0) | (0, 0, 0, 5)   | 3259.069904 | 3289.174941 |
| 4 | (0, 1, 1) | (1, 0, 0, 5)   | 3259.433099 | 3294.530507 |
| 5 | (0, 1, 1) | (0, 0, 0, 5)   | 3265.519564 | 3295.619222 |

|   | trend | seasonal | damped_trend | MAE       |
|---|-------|----------|--------------|-----------|
| 0 | add   | NaN      | True         | 17.919971 |
| 1 | NaN   | NaN      | False        | 17.920960 |
| 2 | add   | add      | True         | 17.923960 |

|   | Modelo        | Configuração final                                | Critério                     |
|---|---------------|---------------------------------------------------|------------------------------|
| 0 | SARIMAX       | (1, 1, 1) / (1, 0, 0, 5)                          | Menor AIC                    |
| 1 | Holt-Winters  | {'trend': 'add', 'seasonal': nan, 'damped_tren... | Menor MAE na validação       |
| 2 | Random Forest | {'max_depth': 6, 'max_features': 'sqrt', 'min_... | Menor MAE no TimeSeriesSplit |
| 3 | XGBoost       | {'colsample_bytree': 0.8, 'learning_rate': 0.0... | Menor MAE no TimeSeriesSplit |

## Validação walk-forward


---

Todos os modelos usam horizonte de um pregão e as mesmas 372 datas de teste. Random Forest, XGBoost e Holt-Winters são reajustados com janela expansiva. O SARIMAX incorpora cada nova observação ao estado do modelo sem reestimar os hiperparâmetros escolhidos.

## Resultados comparativos por MAE

O ranking é calculado exclusivamente com previsões fora da amostra. O erro médio complementa o MAE e indica a direção do viés: valores positivos significam que, em média, o modelo subestimou a abertura.

|   | Ranking | Modelo        | MAE      | Erro_medio | Tempo_seg  |
|---|---------|---------------|----------|------------|------------|
| 0 | 1       | SARIMAX       | 2.647373 | 0.306824   | 29.794674  |
| 1 | 2       | Holt-Winters  | 2.781773 | 0.295228   | 40.796561  |
| 2 | 3       | XGBoost       | 2.933805 | 1.618274   | 133.037812 |
| 3 | 4       | Random Forest | 3.133735 | 1.145289   | 195.468681 |




O melhor resultado desta base é do **SARIMAX**, com MAE de **2.647 USD**. O **XGBoost** ocupa a posição **3**, com MAE de **2.934 USD**. As diferenças são avaliadas apenas dentro desta base, pois MAEs de escalas distintas não devem ser somados.


## Resíduos, ACF e Ljung-Box

Os resíduos são definidos como valor real menos previsão. Primeiro são observados ao longo do tempo; depois, a ACF e o teste de Ljung-Box em 20 defasagens verificam se ainda existe dependência temporal não capturada.

Resíduos fora da amostra ao longo do tempo



ACF dos resíduos fora da amostra




|   | Modelo        | Ljung_Box  | p_valor      | Conclusao_5pct |
|---|---------------|------------|--------------|----------------|
| 0 | SARIMAX       | 31.056401  | 5.445026e-02 | Sem evidência  |
| 1 | Holt-Winters  | 23.309386  | 2.738596e-01 | Sem evidência  |
| 2 | Random Forest | 216.832659 | 5.113588e-35 | Autocorrelação |
| 3 | XGBoost       | 120.987452 | 1.871050e-16 | Autocorrelação |

Ao nível de 5%, há evidência de autocorrelação residual em **Random Forest, XGBoost**. Não há evidência suficiente em **SARIMAX, Holt-Winters**. A autocorrelação remanescente indica que ainda existem padrões temporais que esses modelos não capturaram completamente.

# Importância das features e interpretação

Random Forest e XGBoost usam a importância nativa das árvores. No SARIMAX, são apresentados coeficientes, sinais e p-valores das variáveis externas. Holt-Winters é univariado e, por isso, não possui importância de features.



|    | Modelo        | Feature       | Importancia |
|----|---------------|---------------|-------------|
| 0  | Random Forest | Open_lag_1    | 0.192368    |
| 9  | Random Forest | Close_lag_1   | 0.171473    |
| 2  | Random Forest | Open_lag_3    | 0.142009    |
| 5  | Random Forest | Open_media_5  | 0.130661    |
| 3  | Random Forest | Open_lag_5    | 0.098247    |
| 25 | XGBoost       | Open_media_21 | 0.254115    |
| 20 | XGBoost       | Open_lag_3    | 0.247907    |
| 18 | XGBoost       | Open_lag_1    | 0.187991    |
| 23 | XGBoost       | Open_media_5  | 0.106223    |
| 27 | XGBoost       | Close_lag_1   | 0.072038    |

|   | Variavel             | Coeficiente | p_valor       |
|---|----------------------|-------------|---------------|
| 0 | NASDAQ_Returno_lag_1 | 0.248973    | 9.404641e-38  |
| 1 | VIX_Close_lag_1      | -0.938364   | 5.161350e-54  |
| 2 | Dia_semana_sen       | -0.011149   | 6.396122e-01  |
| 3 | Dia_semana_cos       | 0.018289    | 4.475587e-01  |
| 4 | ar.L1                | -0.426941   | 1.143651e-06  |
| 5 | ma.L1                | 0.202485    | 3.681291e-02  |
| 6 | ar.S.L5              | 0.001308    | 9.588309e-01  |
| 7 | sigma2               | 1.073326    | 1.189051e-292 |

No XGBoost, as três features mais importantes são **Open\_media\_21**, **Open\_lag\_3**, **Open\_lag\_1**. NASDAQ e VIX somam 0.8% da importância nativa; nesta base, o histórico recente da própria Microsoft explica a maior parte da previsão.

# XGBoost - modelo de especialização

---

O XGBoost é um método de *gradient boosting*: árvores rasas são adicionadas em sequência e cada nova árvore busca reduzir os erros do conjunto anterior. A previsão final combina as contribuições de todas as árvores.

## Hipóteses e preparação

O algoritmo não pressupõe linearidade ou normalidade. Ele exige, porém, observações organizadas em tabela e uma separação temporal rigorosa. Por isso, a série é transformada em lags, janelas móveis e variáveis cíclicas. Não é necessária padronização para as árvores, e as linhas iniciais incompletas são removidas.

## Principais hiperparâmetros

- `n_estimators` : quantidade de árvores; mais árvores aumentam a capacidade e o custo.
- `max_depth` : profundidade de cada árvore; valores altos elevam o risco de sobreajuste.
- `learning_rate` : tamanho de cada correção; valores menores normalmente exigem mais árvores.
- `subsample` : fração das observações usada em cada árvore.
- `colsample_bytree` : fração das features disponível em cada árvore.

## Vantagens e limitações

O modelo captura relações não lineares e interações sem exigir uma forma funcional definida. Em contrapartida, depende de hiperparâmetros adequados, pode sobreajustar e não modela o tempo diretamente: toda a memória temporal precisa ser representada pelas features.

## Otimização e interpretação

A configuração é escolhida por busca em grade com `TimeSeriesSplit` e MAE, sem contato com o teste final. A interpretação utiliza importância nativa das árvores. Essa medida indica contribuição relativa para as divisões, mas não prova causalidade e pode favorecer variáveis correlacionadas.

## Conclusões, limitações e recomendações

---

O resultado desta base deve ser interpretado dentro do período analisado. O mercado muda de regime, o horizonte é de apenas um pregão e as variáveis externas entram como valores observados no pregão anterior. Para uso futuro, recomenda-se reestimar os modelos periodicamente e monitorar MAE, viés e autocorrelação dos resíduos.

Não se calculam vitórias nem posição média entre bases neste notebook, pois isso exige os resultados das outras quatro bases. Essa comparação pertence ao relatório consolidado do grupo.

## Referências

---

- Kaggle. [Microsoft Stock Time Series Analysis](#).
- Statsmodels. Documentação de STL, SARIMAX, Exponential Smoothing e Ljung-Box.
- Scikit-learn. Documentação de Random Forest, GridSearchCV e TimeSeriesSplit.
- XGBoost. Documentação do XGBRegressor.
- Material da disciplina de Séries Temporais e enunciado do trabalho.

## Apêndice

---

O arquivo `registro_demandas.csv` registra as atividades de Gabriel Bento. Os CSVs em `resultados` preservam hiperparâmetros, previsões, resíduos, métricas, Ljung-Box, importâncias e coeficientes.

**Síntese final.** O **SARIMAX** venceu nesta base com MAE de **2.647 USD**. O **XGBoost** ficou em **3º lugar**, com MAE de **2.934 USD**. A força da sazonalidade semanal foi **0.000**, indicando que o ciclo de cinco pregões tem pouca relevância diante da tendência e dos choques de mercado.